Projet 6_Détectez des faux billets

Parcours Data Analyst

Xuefei ZHANG_janvier 2022

Sommaire

- Analyse descriptive
- ACP
- Classification - K means
- Modélisation - régression logistique
- Cas pratique: test de programme

M0 - Analyse de statistique descriptive

- **Analyse univariée**
- **Analyse bivariée**

M0 - affichage et nettoyage du jeu de données

```
Data columns (total 7 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   is_genuine    170 non-null    bool
 1   diagonal      170 non-null    float64
 2   height_left   170 non-null    float64
 3   height_right  170 non-null    float64
 4   margin_low    170 non-null    float64
 5   margin_up     170 non-null    float64
 6   length        170 non-null    float64
dtypes: bool(1), float64(6)
memory usage: 8.3 KB
None
Index(['is_genuine', 'diagonal', 'height_left', 'height_right', 'margin_low',
       'margin_up', 'length'],
      dtype='object')
```

Jeu de données bien propre pour l'analyse

Out[20]:

	is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
0	True	171.81	104.86	104.95	4.52	2.89	112.83
1	True	171.67	103.74	103.70	4.01	2.87	113.29
2	True	171.83	103.76	103.76	4.40	2.88	113.84
3	True	171.80	103.78	103.65	3.73	3.12	113.63
4	True	172.05	103.70	103.75	5.04	2.27	113.55

M0 - Analyse univariée
Moyenne, médianne, variance

```
notesO.groupby(by='is_genuine').mean().transpose()
```

is_genuine	False	True
diagonal	171.889857	171.9761
height_left	104.230429	103.9515
height_right	104.145571	103.7759
margin_low	5.281571	4.1435
margin_up	3.334571	3.0555
length	111.660714	113.2072

```
notesO.groupby(by='is_genuine').median().transpose()
```

is_genuine	False	True
diagonal	171.875	172.005
height_left	104.215	103.915
height_right	104.170	103.760
margin_low	5.265	4.080
margin_up	3.335	3.070
length	111.765	113.210

```
# variance empirique
# mesurer la dispersion
notesO.groupby(by='is_genuine').var().transpose()
```

is_genuine	False	True
diagonal	0.088462	0.094852
height_left	0.045424	0.087764
height_right	0.064086	0.085501
margin_low	0.292515	0.098916
margin_up	0.034263	0.039096
length	0.458236	0.144762

À noter que:

- il existe des différences remarquables entre les vrais billets et faux billets sur les 5 variables à l'exception de **diagonal**, en terme de : **moyenne, médiane, variance**
- **Variance**s pour variable **margin_low** et **length** sont surtout grands

M0 - Analyse univariée
barchart, histogram(+kde), boxplot

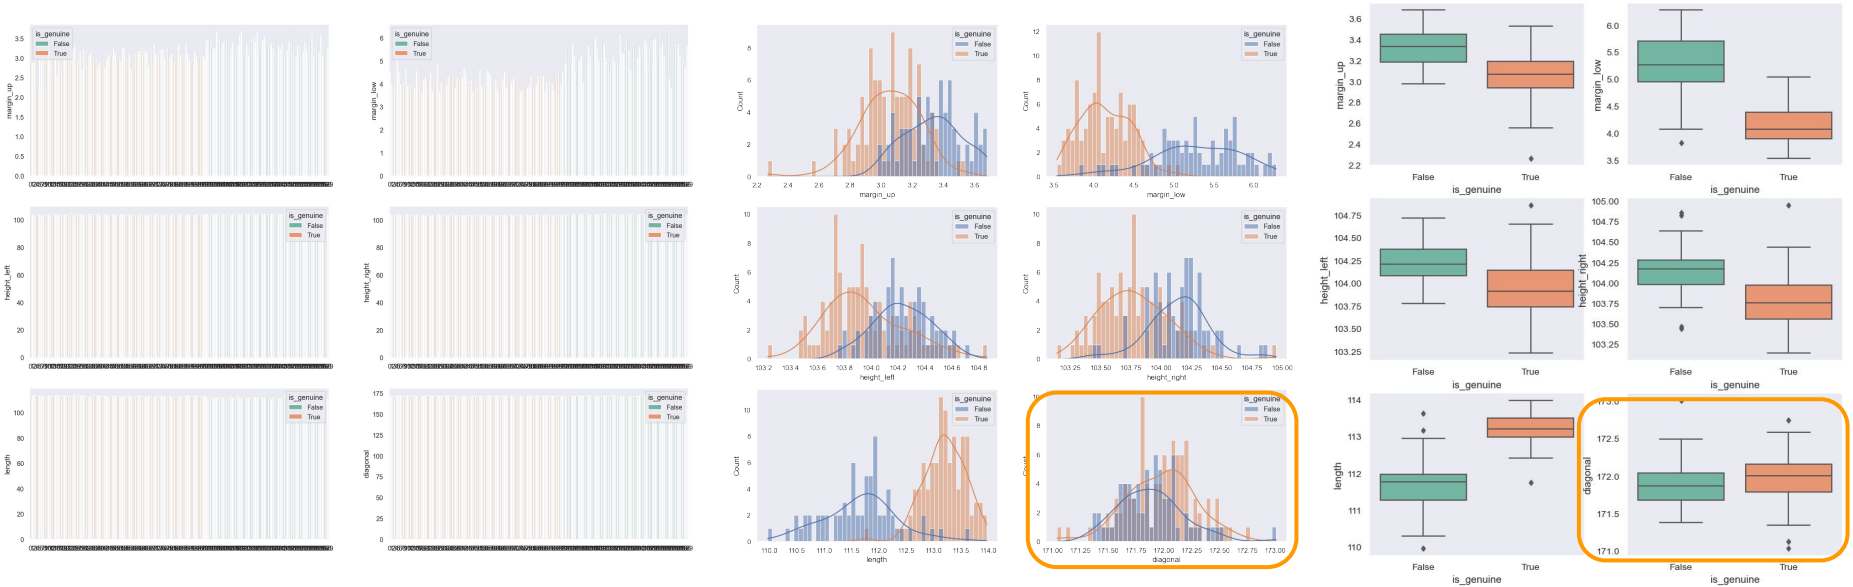

À noter que:
il existe des différences remarquables entre les vrais billets et faux billets sur les 5 variables à l'exception de "diagonal", en terme de : **distribution de densité, quartiles**

M0 - Analyse bivariée
Heatmap de corrélations

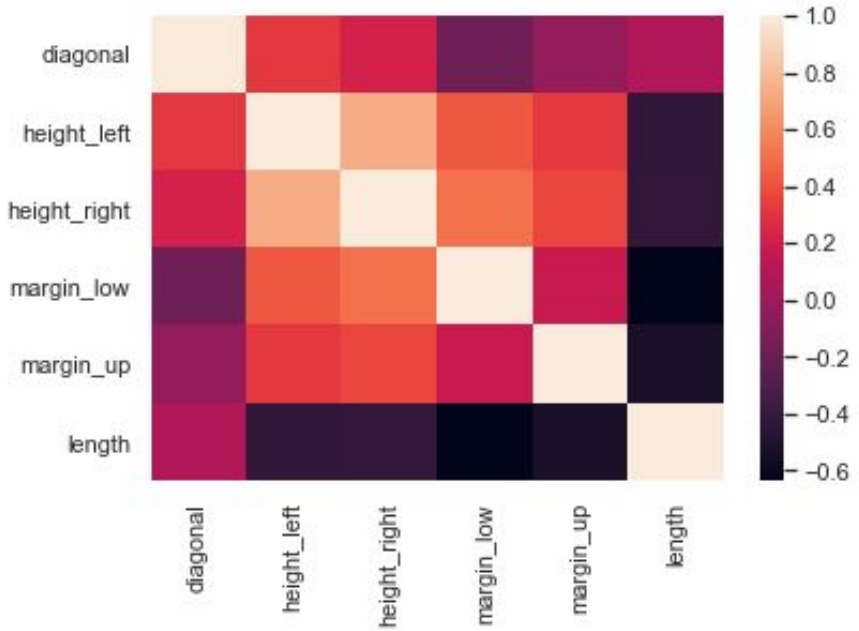

Corrélations entre les variables:

- height_left vs height_right : 70%
- margin_low vs height_right : 50%
- margin_up vs heights : 30%
- length vs heights: - 40%
- margin_up vs length : - 50%
- margin_low vs length : - 60%
- diagonal vs others: -10% – 30%

M0 - Analyse bivariée
Pairplot

Scatter plots:

- Les individus True et False de classification is_genuine se regroupent en 2 partitions sur tous ces 6 variables

Histogrammes:

- Globalement la distribution des valeurs de ces 6 variables suivent **la loi normale**

- Grand écart au sujet de la distribution des individus False/True pour ces 6 variables

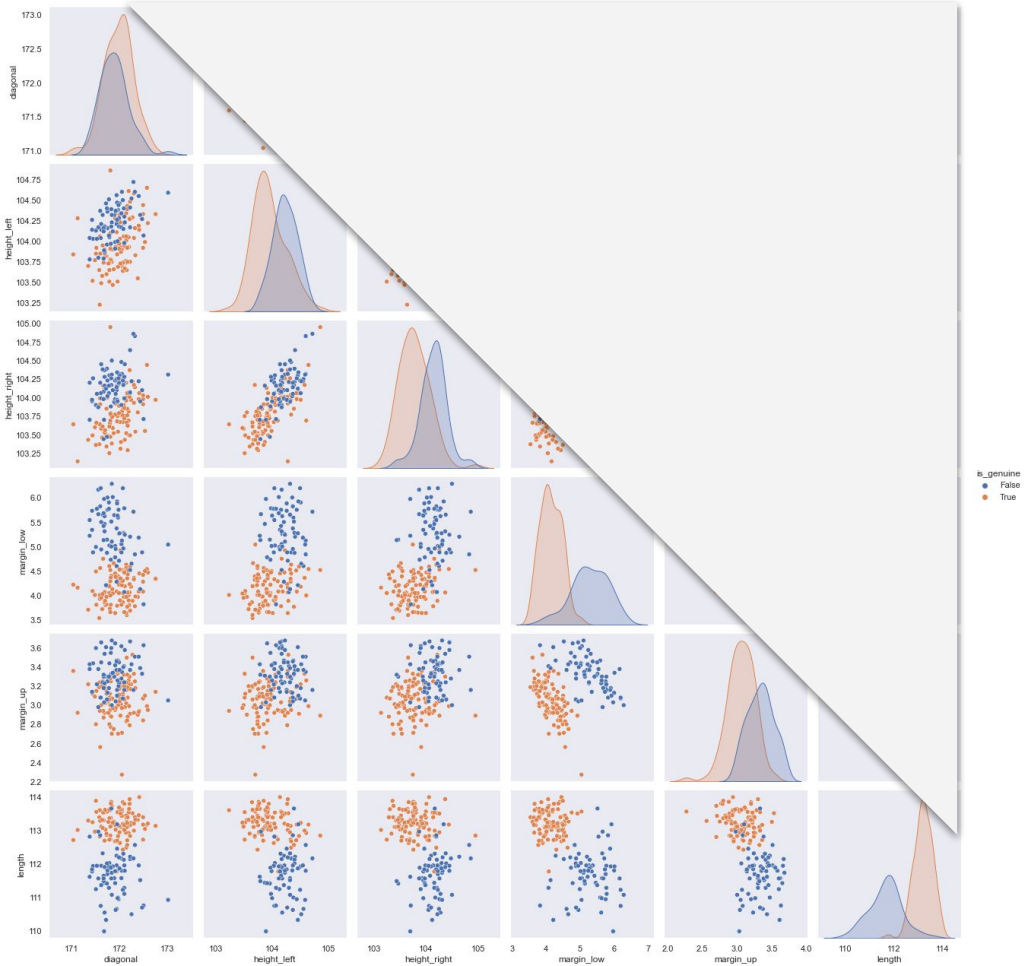

Analyse univariée & bivariée

Ne permettent pas à décortiquer la variabilité entre les individus ni les liaisons entre les variables, ainsi n'arrivent pas à nous sortir des conclusions concrètes pour le but. ☹

=> il faut creuser dans le détail à l'appui d'autres méthodes plus solides et performantes à ce titre: ACP, classification des individus …

M1 - Analyse de Composantes Principales (PCA)

- **éboulis des valeurs propres** ;
- représentation des **variables par le cercle des corrélations** ;
- projection des **individus par les plans factoriels** ;
- analyse de la qualité de **représentation** et la **contribution** des individus.

ACP - Eboulis de valeurs propres (scree plot)

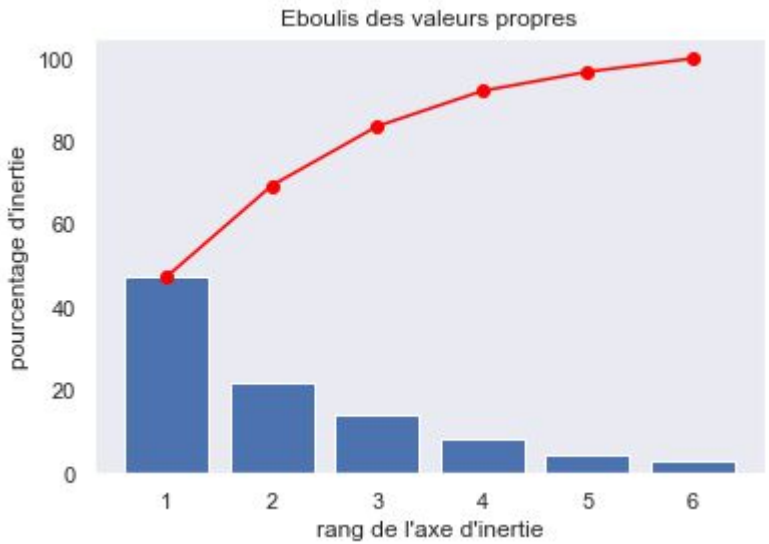

- Les 2 premiers facteurs (le 1er plan factoriel) représentent environ **70%** de l'inertie
- Les 3 premiers facteurs représentent environ **80%** de l'inertie
- Les 4 premiers facteurs (les 2 premiers plans factoriels) représentent environ **90%** de l'inertie

=> On pourrait s'arrêter au 2ème ou 4ème facteurs vu que les deux/quatre premiers facteurs conservent déjà **70%/90%** d'informations.

ACP - représentation des variables par cercles de corrélations

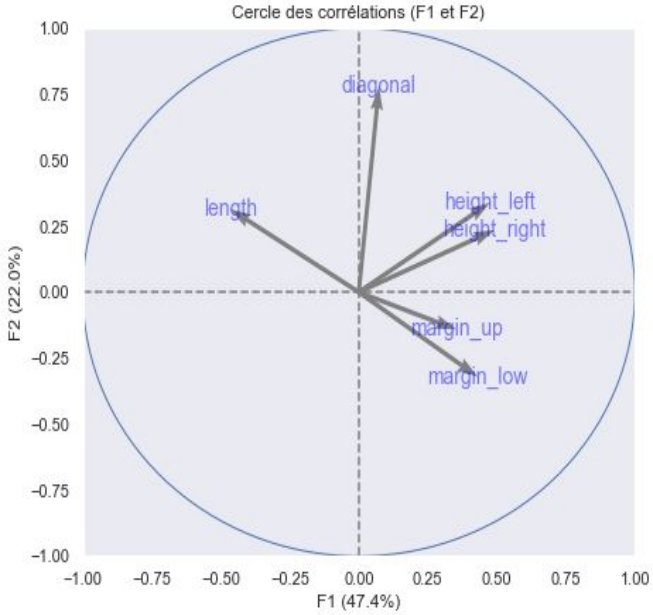

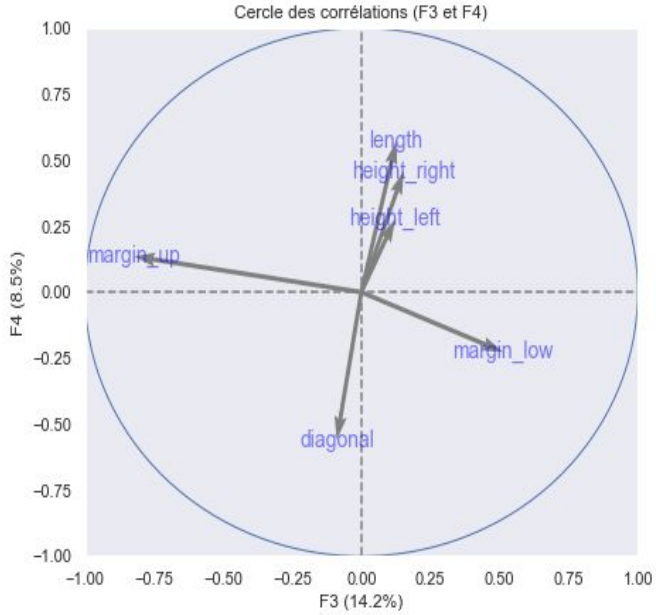

- le **1er plan** représente globalement bien les 6 variables
- **diagonal** est quasiment superposé avec F2 au sens positif, et longue flèche => très bien représenté par 1er plan factoriel
- sur le 1er et 2ème plan, **height_left et height_right** se corrèlent bien (vu l'angle entre eux)
- **margin_up** flèche longue et petit angle avec F3 au sens négatif => bien représenté par F3 au sens négatif

ACP - Projection des individus par 2 plans factoriels - nuage de points

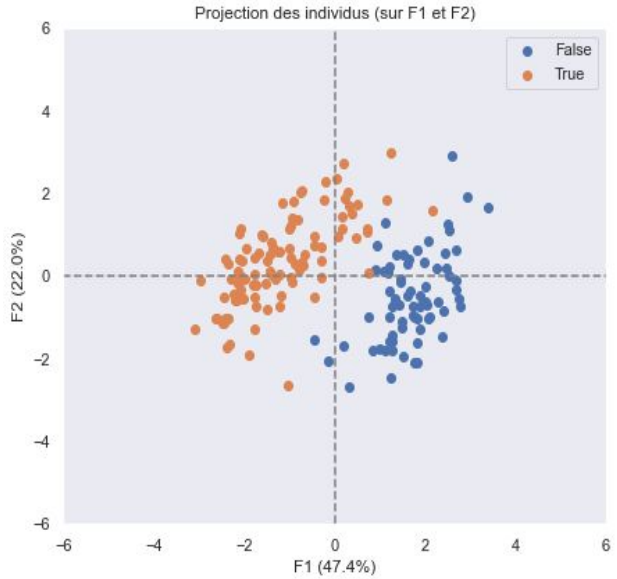

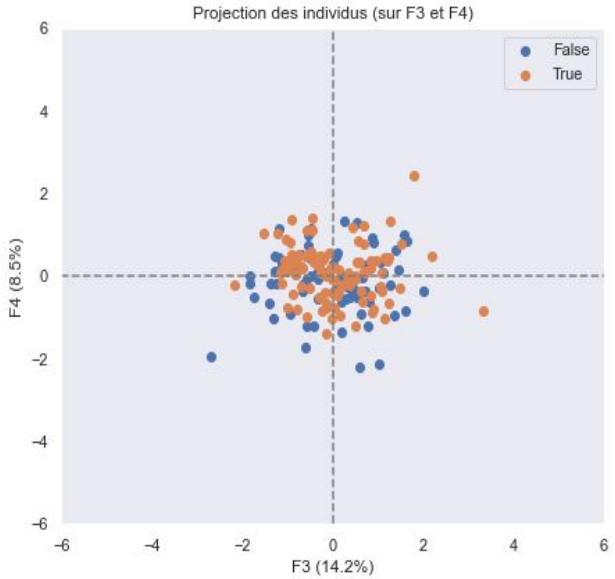

* variable illustrative: **is_genuine** (**False**/**True**)

- Les individus False et True se distinguent et se groupent en 2 clusters sur le 1er plan factoriel
- Sur 2ème plan, il n'y a pas de clusters clairement formés

ACP - Qualité de représentation des individus

In [214]:
```
cos2 = coord**2
print(cos2.shape)

for j in range(p):
    cos2[:,j] = cos2[:,j]/di

repres= pd.DataFrame({'genuine':notesO.index,'COS2_1':cos2[:,0],'COS2_2':cos2[:,1]})
repres

#comme ça, Les COS² pour les 2 premiers facteurs sont affichés
```

(170, 6)

Out[214]:

	genuine	COS2_1	COS2_2
0	0	0.251929	0.139000
1	1	0.818002	0.050822
2	2	0.784862	0.000466
3	3	0.882856	0.001652
4	4	0.320145	0.009417
...	...	...	...
165	165	0.800651	0.004703
166	166	0.324059	0.411824
167	167	0.498809	0.083461
168	168	0.156908	0.271800
169	169	0.421817	0.217111

170 rows × 3 columns

Cosinus carrés

*COS2_1, COS2_2: Qualité de représentation des 170 individus sur les 2 premiers facteurs (1er plan factoriel)

Conformément à la théorie de projection, pour chaque individu, la **somme des COS² sur l'ensemble des 6 facteurs** est égale à **1**.

```
print(np.sum(cos2,axis=1))
```

```
[1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.
 1. 1.]
```

ACP - Contribution des individus aux facteurs

ctr: permet de déterminer les individus qui pèsent le plus dans la définition de chaque facteur.

In [216]:
```
#contributions aux axes
ctr = coord**2
for j in range(p):
    ctr[:,j] = ctr[:,j]/(n*eigval[j])

ctr_axes= pd.DataFrame({'genuine': notesO.index,'CTR_1':ctr[:,0],'CTR_2':ctr[:,1]})
# ici on prends axe 1 et 2

ctr_axes.sort_values(by="CTR_1", ascending= False ).head()
# les 5 individus qui contributent le plus aux CTR_1
```

Out[216]:

	genuine	CTR_1	CTR_2
122	122	0.023758	0.012372
49	49	0.019620	0.007487
29	29	0.018089	0.000038
112	112	0.017950	0.016259
158	158	0.015836	0.002423

Conformément à la théorie, pour chaque axe, la **somme des contributions des individus sur cette axe** est égale à **1**.

In [217]:
```
#vérifions la théorie
print(np.sum(ctr,axis=0))
```

```
[1. 1. 1. 1. 1. 1.]
```

ACP - corrélations des 6 variables avec F1 et F2 (1er plan factoriel)

	id	COR_1	COR_2
0	diagonal	0.123635	0.894863
1	height_left	0.802300	0.389389
2	height_right	0.829835	0.270354
3	margin_low	0.727258	-0.367910
4	margin_up	0.594829	-0.161976
5	length	-0.785209	0.361022

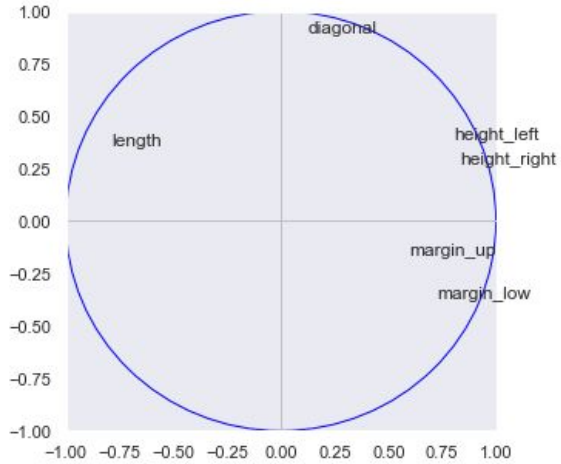

Constatations:

- **4 variables (height_left, height_right, margin_up, margin_low)** sont positivement corrélées avec **F1** et les coeff de corrélation élevés (>0.6);
- **diagonal** n'est pas bien corrélé avec F1, mais bien corrélé avec F2 au sens positif (0.89);
- **length** négativement corrélé avec F1 à un coeff - 0.78

ACP - Qualité de représentation des variables (COS²)

In [215]:
```
#cosinus carré des variables sur F1 et F2
cos2var = corvar**2
print(cos2var.shape)
repres_variables = pd.DataFrame({'id':notes.columns,'COS2_1':cos2var[:,0],'COS2_2':cos2var[:,1]})
repres_variables['COS2_1+2'] = repres_variables['COS2_1'] + repres_variables['COS2_2']
repres_variables
```

(6, 6)

Out[215]:

	id	COS2_1	COS2_2	COS2_1+2
0	diagonal	0.015286	0.800781	0.816066
1	height_left	0.643685	0.151624	0.795308
2	height_right	0.688626	0.073091	0.761717
3	margin_low	0.528904	0.135358	0.664262
4	margin_up	0.353822	0.026236	0.380058
5	length	0.616553	0.130337	0.746890

Constatation:

- F1 représente bien 5 variables sauf diagonal
- F2 représente bien diagonal
- F1+F2 (COS2_1+2) représente dans son ensemble bien ces 6 variables

In [224]:
```
#verification qualité repésentation des variables sur facteurs
print(np.sum(cos2var,axis=1))
```

[1. 1. 1. 1. 1. 1.]

La somme des COS² sur toutes les composantes sont égales à 1 (la **somme des COS² d'une variable sur l'ensemble des 6 facteurs** est égale à **1**)

ACP - Contribution des variables aux axes (CTR)

In [128]:
```
#contributions
ctrvar = cos2var

for k in range(p):
    ctrvar[:,k] = ctrvar[:,k]/eigval[k]

# ici on n'affiche que pour les deux premiers axes
contri_variables= pd.DataFrame({'id':notes.columns,'CTR_F1':ctrvar[:,0],'CTR_2':ctrvar[:,1]})
contri_variables
```

Out[128]:

	id	CTR_1	CTR_2
0	diagonal	0.005369	0.607837
1	height_left	0.226102	0.115091
2	height_right	0.241888	0.055480
3	margin_low	0.185784	0.102744
4	margin_up	0.124284	0.019915
5	length	0.216572	0.098933

Constatation:

- Les 5 variables sauf diagonal contribuent proportionnellement pas mal à F1
- Diagonal contribue 60% à F2

In [233]:
```
#verification contributions des variables aux axes
print(np.sum(ctrvar,axis=0))

print(np.sum(contri_variables,axis=0))
```

```
[1. 1. 1. 1. 1. 1.]
id      diagonalheight_leftheight_rightmargin_lowmargi...
CTR_1                                                1.0
CTR_2                                                1.0
```

Pour chaque axe, la **somme des contributions de tous ces 6 variables** sur chaque axe est égale à **1**. Ainsi on a [1.1.1.1.1.1] vu qu'on a 6 axes-facteurs.

M2 - Classification des individus: K means

- Appliquez un **algorithme de classification**, puis analysez le résultat obtenu.
- Visualisez la partition obtenue dans le 1er plan factoriel de l'ACP, puis analysez-la

M2 - algorithme de classification K-means

Pourquoi K-means ?

- On sait déjà **le nombre de clusters** à sortir soit 2
- K-means est **bien liée avec ACP**
- **Efficacité** de méthode K-means

* Mais on pourrait aussi employer classification hiérarchique vu le volume d'observations n'est pas grand.

In [301]:
```
notesO.head()
```

Out[301]:

is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
True	171.81	104.86	104.95	4.52	2.89	112.83
True	171.67	103.74	103.70	4.01	2.87	113.29
True	171.83	103.76	103.76	4.40	2.88	113.84
True	171.80	103.78	103.65	3.73	3.12	113.63
True	172.05	103.70	103.75	5.04	2.27	113.55

In [306]:
```
# Nombre de clusters souhaités
n_clust = 2

# préparation des données pour le clustering
X = notesO.values

# Réduire n'est ici pas nécessaire car les variables sont exprimées dans la même unité
#X_scaled = preprocessing.StandardScaler().fit_transform(X)

# Centrage et Réduction
std_scale = preprocessing.StandardScaler().fit(X)     # centrage
X_scaled = std_scale.transform(X)                     # reduction


# Clustering par K-means
km = KMeans(n_clusters=n_clust)
km.fit(X)

# Récupération des clusters attribués à chaque individu
clusters = km.labels_

# Affichage du clustering par projection des individus sur le premier plan factoriel
pca = decomposition.PCA(n_components=n_comp).fit(X_scaled)
X_projected = pca.transform(X_scaled)
```

M2 - K means

Projection des individus en 2 clusters sur le 1er plan factoriel ACP

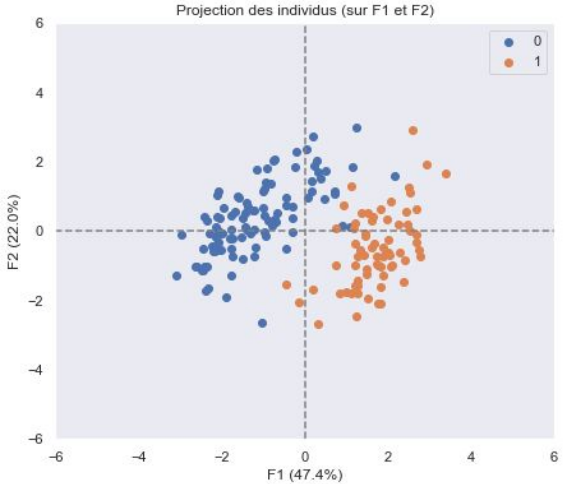

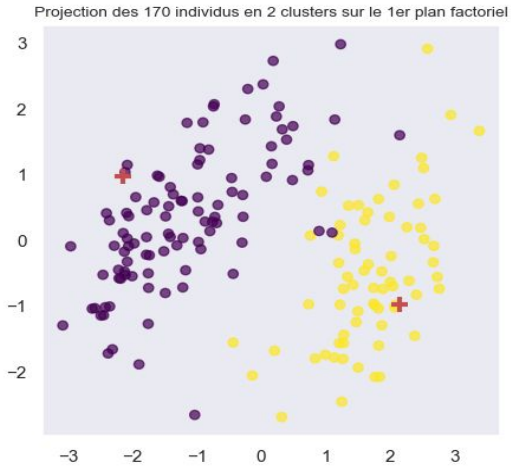

Constatation:

Sur le 1er plan factoriel, les 2 clusters-partitions se distinguent clairement.

Vu que le 1er plan représente environ **70%** d'inertie et la plupart des variables (diagonal, length, height_left, height_left, margin_low) y sont projetées de bonne qualité (COS2 élevés), on dirait que **cette projection des clusters sur 1er plan a du sens** et on pourrait y faire confiance.

M2 - K means
Matrice de confusion

Matrice de confusion

col_0	False	True
cluster1	68	1
cluster2	2	99

- 2 faux billets sont classés dans cluster2 qui représente globalement billets vrais (99/101)
- 1 vrai billet est classé dans cluster1 qui représente globalement billets faux (68/69)

On sait qu'il existe au total 170 billets dont 100 vrais billets et 70 faux,

donc le taux d'erreur = 3/170 = 1.76%

=> cette K-means clustering qu'on a appliqué est dans sa globalité bonne pour ce cas

M3 - Modélisation par régression logistique

L'objectif de la régression logistique est de modéliser, de classifier, une variable binaire prenant ses valeurs dans {0,1} en fonction de variables explicatives quantitatives (et potentiellement qualitatives).

Le Y à prédire est une variable qualitative binaire,

et qu'il existe de multiples variables (6) explicatives quantitatives qui jouent sur la prédiction de Y

=> régression logistique

M3 - Régression logistique

Est-il correct de choisir le modèle régression logistique?

In [313]:
```
model = LogisticRegression()
model.fit(X,y)                    # entrainer le model avec méthode fit

probabilities= model.predict_proba(X)
probabilities
```

In [317]:
```
notesO['predict'] = model.predict(X)
notesO.head()
```

Out[317]:

is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length	predict
True	171.81	104.86	104.95	4.52	2.89	112.83	True
True	171.67	103.74	103.70	4.01	2.87	113.29	True
True	171.83	103.76	103.76	4.40	2.88	113.84	True
True	171.80	103.78	103.65	3.73	3.12	113.63	True
True	172.05	103.70	103.75	5.04	2.27	113.55	True

In [147]:
```
pd.crosstab(notesO['is_genuine'], notesO['predict'])
```

Out[147]:

is_genuine	predict False	predict True
False	69	1
True	1	99

In [327]:
```
print("2/170 individus sont mal placés dans cette matrice, donc le taux d'erreur est 2/170 = ",
      round(2/170, 3))
```

2/170 individus sont mal placés dans cette matrice, donc le taux d'erreur est 2/170 = 0.012

In [328]:
```
from sklearn.metrics import accuracy_score
accuracy_score(notesO['is_genuine'], notesO['predict'])
```

Out[328]: 0.9882352941176471

performance du mode > 98%, donc on pourrait dire que c'est un bon modèle pour la prédiction

M3 - Régression logistique
Entraînement et test de modèle logistique

Split de jeu de données

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y,  test_size=0.2, random_state= 42)

print("Training features/target:", X_train.shape, y_train.shape)
print("Testing features/target:", X_test.shape, y_test.shape)
```

```
Training features/target: (136, 6) (136,)
Testing features/target: (34, 6) (34,)
```

Entrainement et test

```
logmodel = LogisticRegression(penalty='l2', C=0.1)
logmodel.fit(X_train, y_train)                    # entrainer logmodel avec train data. méthode fit()

y_pred = logmodel.predict(X_test)                 #prédire y avec X_test
y_pred_proba = logmodel.predict_proba(X_test)[:,1]
print(y_pred)
print(y_pred_proba)
```

20% de jeu de données (test_size=0.2) sont pour le **test**, autrement dit **80%** pour l'**entraînement** de modèle

M3 - Régression logistique

Niveau de précision de logmodel

```
print("Accuracy score of logmodel for test data: ",
    round(metrics.accuracy_score(y_test, y_pred), 4))

# ici y_test est dataset existant de y pour test, y_pred est le y prédit par logmodel via x_test
```

Accuracy score of logmodel for test data: 0.9706

> 97%: logmodel est performant

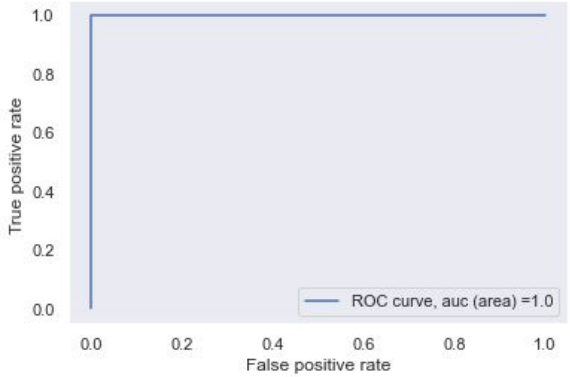

AUC =1, ctd. Il y a 100% de chance que logmodel est en mesure de distinguer les individus de classe positive de ceux de classe négative.

M3 - Régression logistique

Optimisation de choix de variables avec RFE

```
from sklearn.feature_selection import RFE

selector = RFE(logmodel, step=1)                    #recursive feature elimination (RFE) is to select features by recursive
selector = selector.fit(X_train, y_train)
selector.support_
```

```
array([False, False,  True,  True, False,  True])
```

```
print("Selon selector, ces variables sont choisies pour la prise de décision False/True: ",  np.array(notes.columns)[[2,3,-1]])
```

```
Selon selector, ces variables sont choisies pour la prise de décision False/True  ['height_right' 'margin_low' 'length']
```

```
print(selector.predict(X_test))

print("proba False I  proba True: ")
print(selector.predict_proba(X_test))
```

```
[False  True False  True False False False  True False  True  True False
 False  True  True  True  True False  True False  True  True  True  True
  True  True  True  True  True  True  True  True False False]
proba False I  proba True:
[[0.71481126 0.28518874]
 [0.09752728 0.90247272]
 [0.77331092 0.22668908]
 [0.06721685 0.93278315]
 [0.57902677 0.42097323]
```

RFE:
Éliminer variables qui jouent peu dans la prédiction (ctd. Variables de faible importance dans la prise de décision)

```
print("Matrice de confusion_selector")
pd.crosstab(selector.predict(X_test),y_test)
```

Matrice de confusion_selector

is_genuine	False	True
row_0		
False	12	0
True	0	22

```
print("Accuracy score of selector for test data: ", metrics.accuracy_score(selector.predict(X_test),
# selector: logmodel avec 'features' optimisés
```

```
Accuracy score of selector for test data: 1.0
```

Algorithme **selector** arrive à distinguer les vrais et faux billets à **100%**

M4 - Cas pratique: test de l’algorithme

M4 - Cas pratique: simulation - test de l'algorithme

n [403]:
```
example = pd.read_csv("example.csv")
example.head()
```

ut[403]:

	diagonal	height_left	height_right	margin_low	margin_up	length	id
0	171.76	104.01	103.54	5.21	3.30	111.42	A_1
1	171.87	104.17	104.13	6.00	3.31	112.09	A_2
2	172.00	104.58	104.29	4.99	3.39	111.57	A_3
3	172.49	104.55	104.34	4.44	3.03	113.20	A_4
4	171.65	103.63	103.56	3.77	3.16	113.33	A_5

n [404]:
```
from sklearn.linear_model import LogisticRegression
XX = example.drop(['id'], axis=1).values
XX
```

ut[404]:
```
array([[171.76, 104.01, 103.54,   5.21,   3.3 , 111.42],
       [171.87, 104.17, 104.13,   6.  ,   3.31, 112.09],
       [172.  , 104.58, 104.29,   4.99,   3.39, 111.57],
       [172.49, 104.55, 104.34,   4.44,   3.03, 113.2 ],
       [171.65, 103.63, 103.56,   3.77,   3.16, 113.33]])
```

n [405]:
```
probability =  selector.predict(XX)
proba_percentage =  selector.predict_proba(XX)
print(probability)
print("False % , True %:")
print(proba_percentage)
```

```
[False False False  True  True]
False % , True %:
[[0.71976459 0.28023541]
 [0.85286893 0.14713107]
 [0.78312751 0.21687249]
 [0.30729561 0.69270439]
 [0.08078442 0.91921558]]
```

```
df = pd.DataFrame({'ID': example['id'], "Genuine": probability,
                   "Proba_False": proba_percentage[:,0],
                   "Proba_True": proba_percentage[:,1]})
df
```

	ID	Genuine	Proba_False	Proba_True
0	A_1	False	0.719765	0.280235
1	A_2	False	0.852869	0.147131
2	A_3	False	0.783128	0.216872
3	A_4	True	0.307296	0.692704
4	A_5	True	0.080784	0.919216

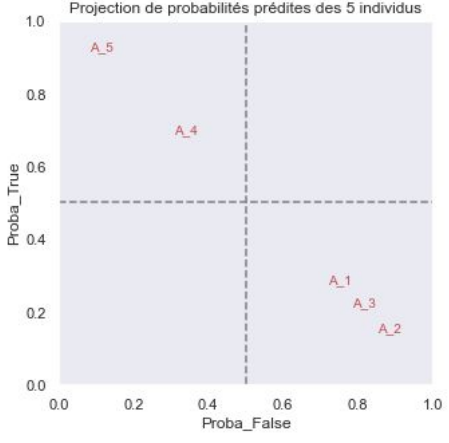

Q & A

MERCI !